Тестовое задание

Задача связана с constrained generation / ограничениями на генерацию LLM. Основная цель - **разобраться в методе, реализовать логику проверки и откатов, провести эксперименты**.

Что проверяем этим заданием?

- умеешь ли читать и разбирать статью
- можешь ли реализовать метод со статьи и понять, за счет чего он работает
- сможешь ли поставить эксперимент, а затем еще объяснять, что получилось, а что - нет
- уровень и качество реализации, аккуратность представления результата

Часть 1. IterGen на генерации SQL

Первая задача - воспроизвести идею IterGen из SQL-эксперимента статьи на небольшой модели.

Статья: IterGen: Iterative Semantic-aware Structured LLM Generation with Backtracking - https://arxiv.org/pdf/2410.07295

Базовая модель: Qwen3.5-0.8B.

Этапы:

1) Разобраться в статье: как работает откат и чем он отличается от повторной генерации всего ответа?

2) Поднять baseline: обычную генерацию и SynCode.

3) Взять 50 примеров из SQL-эксперимента авторов / Spider, минимум из 5 баз. Отдельно выбрать 5 примеров для отладки.

4) На IterGen реализовать свой цикл.

5) Выбрать и обосновать моменты проверки.

Часть 2. Абляция и разбор ошибок

Теперь нужно проверить, за счет чего работает метод и какой ценой.

Этапы:

1) Сравнить три режима: обычную генерацию, SynCode и свой контроллер IterGen. И объяснить, какие части метода воспроизведены, а где есть отличия от статьи.

2) Отдельно посчитать долю запросов, которые выполняются без ошибок, и execution accuracy. Сравниваем время, число откатов и число сгенерированных токенов.

3) Провести абляции. Хочется увидеть, в каких случаях дополнительные откаты помогают, а в каких - нет.

4) Разобрать 4-5 конкретных примеров. Для каждого показать запрос, сработавшую проверку / трассу и объяснение. Если какого-то случая не оказалось, отдельно собрать пример и не включать его в общую метрику.

5) Сформулировать, что из результатов можно переносить на LLM-агентов. Какие ограничения можно проверять снаружи модели, что меняется, когда допустимые действия зависят от состояния, и чего SQL-эксперимент пока не проверяет?

Бонус

Добавить бейзлайн с повторной генерацией всего SQL после ошибки и сравнить с локальным откатом при сопоставимом бюджете токенов. Посмотреть, дает ли сам откат что-то сверх дополнительных попыток.

По обеим частям хочется получить код/ноутбук с инструкцией запуска, артефакты экспериментов (предсказания, метрики и трассы) и краткий отчет на 2-3 страницы. В коде указать, что взято у авторов, а что реализовано самостоятельно.